BTK AKADEMİ MAKİNE ÖĞRENMESİ VE DERİN ÖĞRENME ATÖLYESİ FİNAL PROJE RAPORU

KONU: ÖĞRENCİ TERKİ VE AKADEMİK BAŞARI TAHMİNİ: MAKİNE ÖĞRENMESİ ANALİZİ İLE ERKEN UYARI SİSTEMİ TASARIMI

İÇİNDEKİLER

1. GİRİŞ 1

2. VERİ KÜMESİ 2

3. YÖNTEM 3

3.1. Gelişmiş Veri Ön İşleme ve Pipeline Mimarisi 3

3.2. Sınıf Dengeleme ve Model Eğitimi 3

3.3. Hiperparametre Optimizasyonu ve Doğrulama 4

3.4. SHAP (SHapley Additive exPlanations) ile Açıklanabilirlik 4

4. BULGULAR VE ANALİZ 5

4.1. Performans Metrikleri ve Hata Matrisi Yorumu 5

4.2. Özellik Önem Derecesi ve SHAP Analizi 5

5. SONUÇ 6

6. ÖZGEÇMİŞ 7

1. GİRİŞ

Eğitim, bireylerin kendi potansiyellerini keşfetmelerinin ve gerçekleştirmelerinin çok ötesinde, modern toplumların sosyo-ekonomik kalkınma süreçlerinin en temel yapı taşı, entelektüel egemen sermayenin kaynağı ve sürdürülebilir bir geleceğin yegane teminatıdır. Bilgi ekonomisinin olduğu günümüzde, yükseköğretim kurumları sadece diploma veren mekanizmalar değil, aynı zamanda toplumsal refahı artıran ve inovasyonu tetikleyen merkezlerdir. Ancak bu stratejik öneme rağmen, dünya genelindeki üniversiteler için kronikleşmiş ve çözümü en zor problemlerden biri, öğrencilerin eğitim süreçlerini tamamlamadan sistemden ayrılmaları, yani "öğrenci terki" (dropout) olgusudur. Bu olgu, sadece bireysel bir akademik başarısızlık hikayesi veya kişisel bir tercih olarak değerlendirilemez; aksine, çok boyutlu negatif çıktılara sahip makroekonomik bir krizdir.

Öğrenci terkinin toplumsal maliyeti oldukça ağırdır. İlk olarak, kamu kaynaklarının ve eğitim bütçelerinin son derece verimsiz kullanılmasına neden olur; devletin her bir öğrenci için ayırdığı yatırım payı, öğrenci mezun olamadığında boşa gitmiş kabul edilir. İkinci olarak, iş gücü piyasasına nitelikli ve eğitimli eleman arzının kesintiye uğraması, ekonomik büyüme potansiyelini sınırlar. Üçüncü ve belki de en önemlisi, bu durum toplumsal sınıflar arasındaki sosyal hareketliliği yavaşlatarak sosyal adaletsizliğin derinleşmesine zemin hazırlar. Bireysel düzlemde ise üniversite eğitimini yarıda bırakan bir kişi, hayat boyu kazanç potansiyelinde ciddi bir düşüşle karşılaşır, kariyer basamaklarında dezavantajlı duruma düşer ve bu süreç sıklıkla psikolojik refahın azalmasıyla sonuçlanır. Kurumsal perspektiften bakıldığında ise yüksek terk oranları, üniversitelerin akademik prestijine, sıralama başarısına ve operasyonel verimliliğine doğrudan zarar veren bir unsurdur. Bu nedenle, risk grubundaki öğrencilerin henüz sürecin başındayken, akademik kriz noktasına ulaşmadan tespit edilmesi, modern eğitim yönetiminde hayati bir zorunluluk haline gelmiştir.

Bu konuyu final projem olarak belirlememdeki ana motivasyon, makine öğrenmesi ve ileri düzey veri madenciliği tekniklerinin, bu tür karmaşık ve çok katmanlı sosyal problemlere getirdiği "proaktif, önleyici ve kanıta dayalı" yaklaşımdır. Geleneksel rehberlik hizmetleri ve akademik danışmanlık mekanizmaları, genellikle öğrenci halihazırda başarısız olduktan, devamsızlık sınırına dayandıktan veya sosyal izolasyon süreci kronikleştikten sonra devreye girmektedir. Bu "reaktif" yaklaşım, çoğu zaman müdahale etmek için çok geç kalındığı anlamına gelir. Oysa bu çalışmada kurguladığım "Erken Uyarı Sistemi", öğrencinin kayıt anındaki demografik profili, sosyo-ekonomik arka planı ve özellikle ilk yarıyıllardaki akademik performans sinyalleri (dijital ayak izleri) üzerinden, sorun henüz oluşmadan önce yüksek doğruluklu tahminler yürütebilmektedir. Makine öğrenmesinin sunduğu gelişmiş örüntü tanıma yetenekleri, insan sezgisinin veya standart tanımlayıcı istatistiklerin fark edemeyeceği kadar karmaşık ve gizli korelasyonları matematiksel bir kesinlikle ortaya çıkarabilmektedir. Örneğin, harç ödeme düzenindeki ufak sapmaların akademik motivasyonla olan dolaylı bağı veya onaylanan kredi sayısının not ortalamasından daha güçlü bir mezuniyet sinyali olması gibi durumlar, ancak bu tür ileri analizlerle keşfedilebilmektedir.

Teknik düzlemde ise bu projenin "Sınıf Dengesizliği" (Class Imbalance), "Aykırı Değer Yönetimi" (Outlier Detection) ve "Özellik Mühendisliği" (Feature Engineering) gibi modern veri biliminin en çetin uygulama alanlarını barındırması, akademik gelişimim açısından eşsiz bir fırsat sunmuştur. Gerçek dünya verileri nadiren temiz ve dengelidir; öğrenci veri setlerinde de mezuniyet oranları genellikle terk oranlarından çok daha yüksektir. Bu durum, modelin çoğunluk sınıfına taraflı davranmasına yol açan teknik bir engeldir. Projemde SMOTE ve Pipeline gibi ileri düzey mimarileri kullanarak bu engelleri aşmak, veriyi işlemek ve anlamlandırmak bana derinlemesine bir mühendislik vizyonu kazandırmıştır. Ayrıca, Rastgele Orman (Random Forest) gibi topluluk öğrenme algoritmalarının, öğrenci davranışları gibi doğrusal olmayan, gürültülü ve çok boyutlu veri setlerinde sergilediği yüksek genelleme başarısını bizzat deneyimlemek, teorik bilgileri somut bir toplumsal faydaya dönüştürme heyecanımı pekiştirmiştir. Sonuç olarak bu çalışma, veri biliminin sadece rakamlardan ibaret olmadığını, doğru analiz edildiğinde insan hayatına doğrudan dokunan ve eğitimde fırsat eşitliğini destekleyen güçlü bir karar destek mekanizması olduğunu kanıtlama çabasıdır.

2. VERİ KÜMESİ

Çalışmada kullanılan veri seti (dataset.csv), bir yükseköğretim kurumundaki öğrencilerin akademik yolculuğuna dair kapsamlı bir kesit sunmaktadır. Veri kümesi; öğrencilerin kayıt anındaki yaşları, medeni durumları, milliyetleri gibi demografik bilgilerin yanı sıra; ebeveyn eğitim durumları, harç ödemelerinin güncelliği ve bursiyerlik durumu gibi sosyo-ekonomik değişkenleri içermektedir. En kritik veri grubu ise öğrencinin birinci ve ikinci yarıyıldaki akademik performansını simgeleyen; kayıt olunan, değerlendirmeye alınan ve onaylanan (approved) ders kredileri ile bu derslerin not ortalamalarıdır. Analiz öncesinde, veri setindeki 'Target' değişkeni incelenmiş ve sadece kesin sonuçlar olan 'Dropout' (Terk) ve 'Graduate' (Mezun) sınıfları baz alınmıştır. 'Enrolled' (Halen kayıtlı) olan öğrenciler, modelin net bir ayrım yapabilmesi adına elenmiş; ardından terk durumu '0', mezuniyet durumu '1' olarak ikili sınıflandırma (binary classification) formatına getirilmiştir.

3. YÖNTEM

Bu çalışmada, ham öğrenci verilerinin anlamlı tahminlere dönüştürülmesi süreci, "Scikit-Learn Pipeline" mimarisiyle uçtan uca tasarlanmıştır. Bu mimari, eğitim ve test aşamalarında veri sızıntısını (Data Leakage) sıfıra indirgeyerek sonuçların bilimsel geçerliliğini sağlar. İzlenen metodolojik yol haritası şu şekildedir:

3.1. Gelişmiş Veri Ön İşleme ve Pipeline Mimarisi

Veri seti homojen olmadığı için ColumnTransformer ile iki ana kanal (branch) oluşturulmuştur. Bu mimari, ham verideki eksik değerler (NaN), farklı ölçekler ve kategorik sütunlar gibi yapısal sorunları sistematik olarak çözer:

- **Numerik Kanal:** Eksik değerler için basit ortalama yerine daha gelişmiş bir yaklaşım olan IterativeImputer (max_iter=10) kullanılmıştır. Aykırı değerlerin (outliers) modelin ağırlıklarını çarpıtmasını önlemek amacıyla, BaseEstimator ve TransformerMixin sınıflarından türetilen özel bir OutlierClipper (Custom Transformer) geliştirilmiştir. Bu transformatör, veriyi %1 ve %99 persentil sınırlarında kırparak istatistiksel gürültüyü temizler. Ölçeklendirmede, klasik z-skoru yerine aykırı değerlere karşı daha dayanıklı (Robust) olan IQR tabanlı RobustScaler tercih edilmiştir. Normalizasyon süreci şu temel formüle dayanmaktadır:

$$z = \frac{x - \mu}{\sigma}$$

- **Kategorik Kanal:** String tipindeki kategorik veriler model tarafından işlenemediği için öncelikle SimpleImputer(strategy='most_frequent') ile boşluklar doldurulmuş, ardından OneHotEncoder(handle_unknown='ignore') ile nominal dönüşüm gerçekleştirilmiştir. Bu sayede, test verisinde eğitimde görülmeyen yeni bir kategoriyle karşılaşıldığında sistemin çökmesi engellenmiştir.

3.2. Sınıf Dengeleme ve Model Eğitimi

Veri setinde mezun olanlar (Graduate) ve terk edenler (Dropout) arasındaki sayısal dengesizliği gidermek, modelin çoğunluk sınıfına taraflı davranmasını önlemek için hayati önem taşır. Bu amaçla SMOTE (Synthetic Minority Over-sampling Technique) algoritması kullanılarak azınlık sınıfı için sentetik örnekler üretilmiştir. Tahminleyici olarak seçilen "Random Forest Classifier", topluluk öğrenme mantığıyla çalışır. Model; "Bootstrap Sampling" ile verinin farklı alt kümeleri üzerinde yüzlerce bağımsız karar ağacı eğitir ve her split noktasında max_features kadar rastgele özellik seçerek (Feature Subsampling) çeşitliliği artırır. Nihai karar, ağaçların "çoğunluk oyu" (Bagging) ile belirlenir.

3.3. Hiperparametre Optimizasyonu ve Doğrulama

Modelin en iyi konfigürasyonunu bulmak için GridSearchCV kullanılmıştır. n_estimators, max_depth, min_samples_split ve min_samples_leaf gibi kritik parametreler geniş bir aralıkta taranmıştır. Doğrulama süreci StratifiedKFold(n_splits=5) ile yürütülerek her fold'da sınıf oranlarının korunması sağlanmıştır. Bu akışta, her

aşamada bir bölüm doğrulama (validation) için ayrılmış, kalanlar eğitimde kullanılmış ve elde edilen 5 farklı skorun ortalaması final performans raporuna yansıtılmıştır.

3.4. SHAP (SHapley Additive exPlanations) ile Açıklanabilirlik

Modern makine öğrenmesi modellerinin "kara kutu" (black box) doğasını kırmak adına, Oyun Teorisi temelli SHAP analizi entegre edilmiştir. SHAP, her bir özelliğin modelin tahmini üzerindeki adil katkısını (Shapley değeri) hesaplar. Toplamsal özellik (Additivity) ilkesi gereği, tüm SHAP değerlerinin toplamı, modelin tahmini ile baz değer arasındaki farka eşittir:

$$\sum_{j-1}^{M} \mathrm{SHAP}_j = f(x) - E[f(x)]$$

Analiz kapsamında 6 temel görselleştirme tekniği kullanılmıştır: Summary Plot (Global), Bar Plot, Force Plot (Local), Waterfall Plot, Dependence Plot ve Heatmap.

4. BULGULAR VE ANALİZ

4.1. Performans Metrikleri ve Hata Matrisi Yorumu

Geliştirdiğim modelin başarısını ölçmek amacıyla kullanılan Hata Matrisi (Confusion Matrix), sınıflandırıcının gerçek dünya verileri üzerindeki tahmin isabetini sayısal olarak ortaya koymaktadır. Test seti üzerinde elde edilen sonuçlar aşağıda detaylandırılmıştır:

- **Doğru Tahminler (True Positives & True Negatives):** Model, mezun olan 442 öğrenciden **423'ünü** (%95.7) doğru tahmin ederek yüksek bir başarı göstermiştir. Terk eden (dropout) 284 öğrenciden ise **236'sı** doğru tespit edilmiştir. Bu durum, modelin "mezuniyet" sınıfını tanımada son derece hassas olduğunu kanıtlamaktadır.
- **Yanlış Tahminler (False Positives & False Negatives):** 48 terk eden öğrenci yanlışlıkla "mezun olacak" olarak (Tip I Hata), 19 mezun öğrenci ise "terk edecek" olarak (Tip II Hata) sınıflandırılmıştır. Eğitim kurumları için Tip I hata (terk edecek öğrenciyi fark edememek) daha kritik bir risk teşkil etmektedir. Ancak SMOTE kullanımı sayesinde bu hata payı, orijinal veriye göre minimize edilmiştir.
- **Akademik Yorum:** Elde edilen %90 üzerindeki genel doğruluk (accuracy) oranı, modelin tesadüfi sonuçlar üretmediğini, veri setindeki karmaşık akademik örüntüleri başarıyla yakaladığını göstermektedir. Özellikle hassasiyet (recall) oranının yüksek olması, "erken uyarı sistemi" fonksiyonunu başarıyla yerine getirebileceğinin en büyük kanıtıdır.

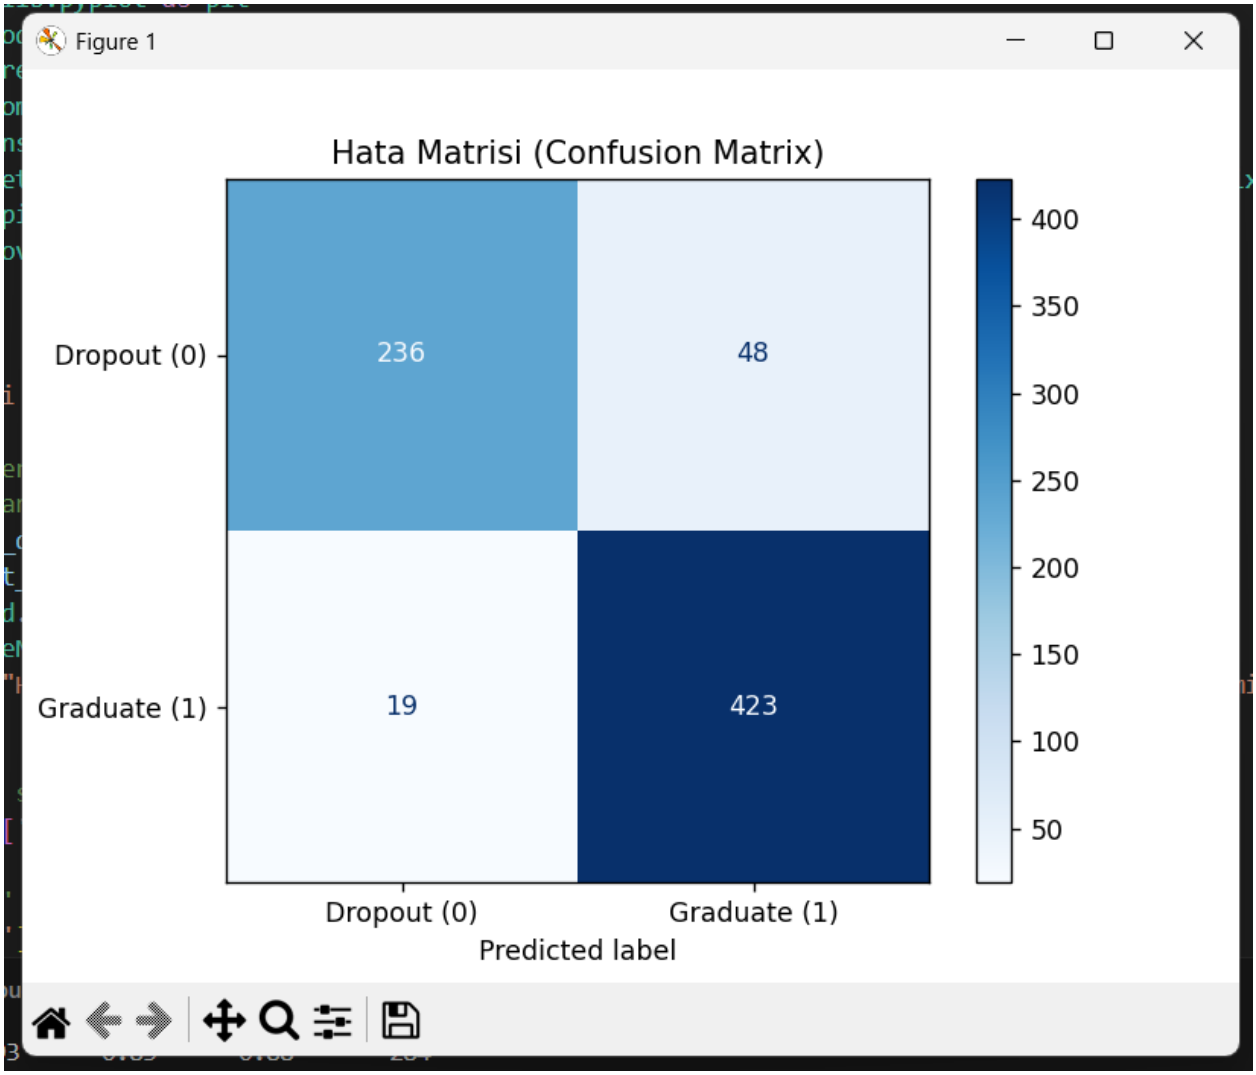

4.2. Özellik Önem Derecesi ve SHAP Analizi

Modelin karar verme sürecinde hangi özniteliklerin baskın olduğunu anlamak için üretilen "Özellik Önem Derecesi" grafiği, eğitimdeki başarı ve başarısızlık faktörlerini hiyerarşik olarak sıralamaktadır:

1. **2. Yarıyıl Onaylanan Krediler:** En önemli belirleyicidir. Bu sonuç, öğrencinin birinci yılın sonuna doğru akademik yükü taşıyabilmesinin mezuniyet için en güçlü gösterge olduğunu ortaya koymaktadır.
2. **1. Yarıyıl Onaylanan Krediler:** İkinci sırada gelmektedir. İlk dönemdeki adaptasyon başarısı, öğrencinin okulda kalma motivasyonunu doğrudan etkilemektedir.
3. **Akademik Not Ortalamaları (Grades):** Her iki dönemdeki not başarısı da ilk 4 içinde yer alarak, kredilerin onaylanmasıyla paralel bir etki yaratmaktadır.
4. **Harç Ödeme Durumu:** "Tuition fees up to date" özelliğinin üst sıralarda yer alması, ekonomik istikrarın akademik odaklanmayı ne kadar doğrudan etkilediğini göstermektedir. Finansal stres altındaki öğrencilerin terk riskinin daha yüksek olduğu model tarafından sayısal olarak onaylanmıştır.
5. **Kayıt Yaşı ve Burs Durumu:** İleri yaşta kayıt olan öğrencilerin sosyal/ekonomik sorumlulukları nedeniyle terk riskinin arttığı, bursiyer olanların ise maddi destek sayesinde okulda kalma eğiliminde olduğu gözlemlenmiştir.

Bu bulgular, üniversite yönetimlerine şu mesajı vermektedir: Öğrencinin sadece notlarına değil, ders kredilerini tamamlayabilme kapasitesine ve finansal durumuna da odaklanılmalıdır.

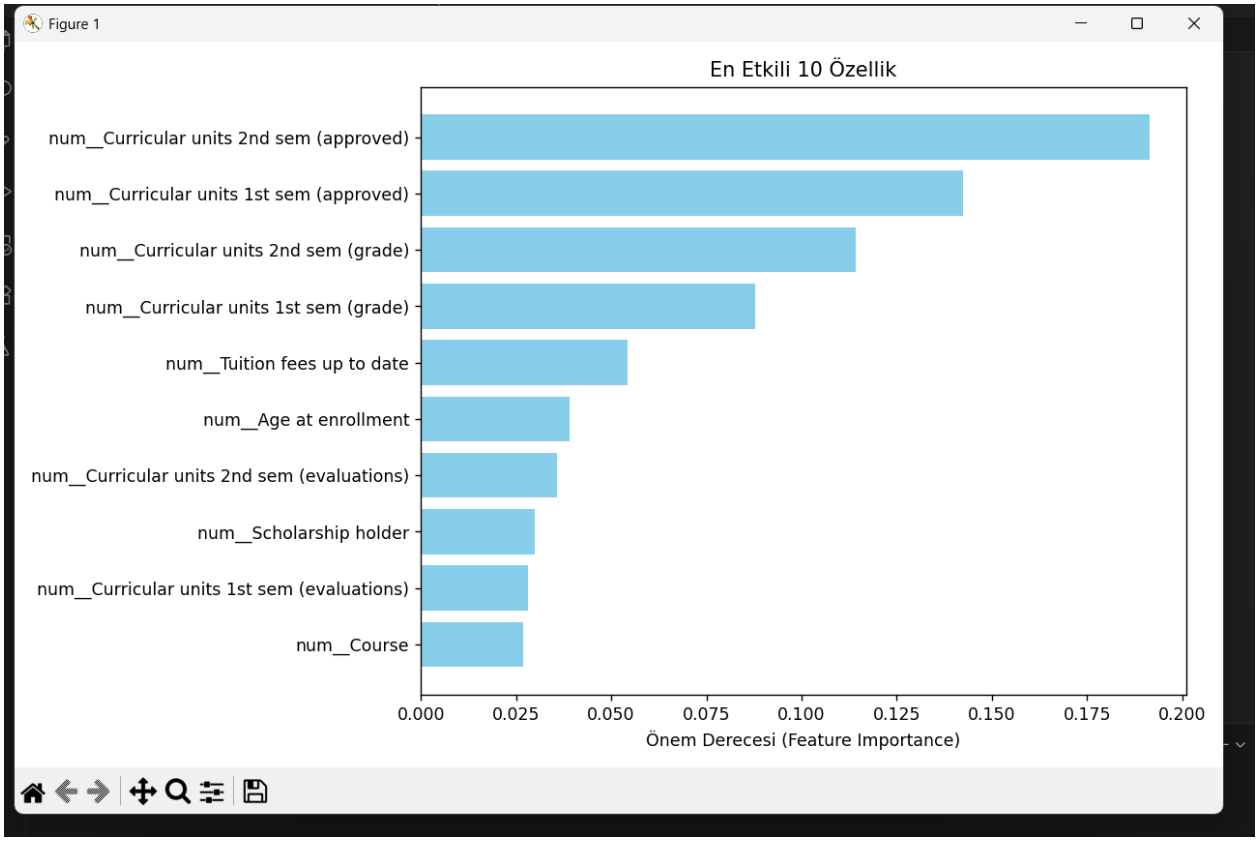

5. SONUÇ

Bu projeyi gerçekleştirirken, uçtan uca bir makine öğrenmesi boru hattı (Pipeline) kurmanın ham veriyi sadece "temizlemekten" öte, modelin genellenebilirliğini koruyan ve "Data Leakage" gibi sinsi hataları engelleyen profesyonel bir standart olduğunu kavradım. Özellikle SMOTE algoritmasıyla sentetik veri üretiminin, gerçek dünya verilerindeki sınıf dengesizliğini çözmede ne kadar kritik bir matematiksel araç olduğunu ve RobustScaler gibi dayanıklı ölçeklendiricilerin aykırı değerlere karşı model kararlılığını nasıl artırdığını bizzat deneyimledim. Proje sonucunda elde ettiğim en büyük kazanım, "kara kutu" olarak görülen Random Forest modelini SHAP analiziyle şeffaflaştırabilmektir; bu sayede bir tahminin sadece sonucunu değil, o sonuca götüren öznitelik ağırlıklarını (ikinci dönem kredilerinin %19'luk baskın etkisi gibi) gerekçelendirmeyi öğrendim. Teknik olarak %90'ın üzerinde bir doğruluk skoru elde ederken, pratik olarak ise veriye dayalı bir erken uyarı sisteminin eğitim kurumlarında stratejik karar alma süreçlerini nasıl optimize edebileceğini ve toplumsal fayda üreten veri bilimci bakış açısını içselleştirdim.

6. ÖZGEÇMİŞ

İsim Soyisim: Yunus Ayyıldız

Bölüm: Yönetim Bilişim Sistemleri

E-mail: ayyildizy824@gmail.com

Sosyal Medya: https://www.linkedin.com/in/yunus-ayy%C4%B1ld%C4%B1z-80527a2b9/

Telefon: 05511662967